BÁO CÁO THỰC NGHIỆM ĐỐI ĐẦU CHUYÊN SÂU: SO SÁNH MSD DEPTH 3 VÀ MSD DEPTH 5

Mô hình nền tảng (Target Model): `Qwen/Qwen2.5-VL-3B-Instruct`
Thuật toán: Multi-modal Speculative Decoding (MSD) với cơ chế Verification & Visual Token Retention
Phạm vi dữ liệu: 3 Benchmark Datasets (`VidHalluc`, `VideoChair`, `VDC`), 4 mức Visual Retention Cut (`100%`, `50%`, `25%`, `0%`), Tổng cộng **2.400 lượt inference hoàn chỉnh**.

I. TỔNG QUAN THỰC NGHIỆM & THIẾT LẬP HỆ THỐNG

1. Mục tiêu thực nghiệm

Thực nghiệm này đối đầu trực tiếp hai biến thể mô hình Drafter trong kiến trúc MSD được huấn luyện trên nền tảng **Qwen 2.5-VL 3B Instruct**:
- **MSD Depth 3**: Drafter thu gọn gồm 3 transformer layers.
- **MSD Depth 5**: Drafter mở rộng gồm 5 transformer layers.
- **Hệ quy chiếu Depth 1**: Sử dụng kết quả baseline kinh nghiệm của cấu hình 1 tầng (DFlash baseline / Qwen2-VL-7B MSD Depth 1) để phân tích quy luật mở rộng chiều sâu tầng (Depth Scaling Law).

Mục tiêu cốt lõi:
1. Đánh giá sự đánh đổi giữa dung lượng mô hình Drafter (Capacity / Depth) với tốc độ sinh speculative decoding.
2. Kiểm tra độ nhạy cảm của Drafter trước việc cắt giảm Visual Tokens (Visual Retention Cuts từ 100% về 0%).
3. **Đánh giá tính "Lossless" thực chất (Semantic Lossless / Performance-based Preservation)** thông qua các chỉ số đo lường tác vụ thực tế (Task Accuracy, ROUGE-L, BLEU-1, Semantic Alignment với Ground-Truth và Target Model) thay vì áp đặt điều kiện quá ngặt nghèo là 100% chuỗi token phải trùng khớp tuyệt đối.

2. Thông số kỹ thuật 2 Checkpoint & Môi trường thực thi

- **Target Model**: `Qwen/Qwen2.5-VL-3B-Instruct` (BF16, Flash Attention / SDPA).
- **Draft Checkpoint Depth 3**:
- Nguồn Hugging Face: `ihbkaiser/qwen25vl-3b-msd-checkpoints` (`qwen25vl-3b-msd-depth3-latest.zip`).
- Cấu trúc: `msd_draft_num_hidden_layers = 3` (các layer index: 0, 1, 2).
- Trạng thái huấn luyện: `global_step = 80000`, `epoch = 37`.
- **Draft Checkpoint Depth 5**:
- Nguồn Hugging Face: `ihbkaiser/qwen25vl-3b-msd-checkpoints` (`qwen25vl-3b-msd-depth5-latest.zip`).
- Cấu trúc: `msd_draft_num_hidden_layers = 5` (các layer index: 0, 1, 2, 3, 4).
- Trạng thái huấn luyện: `global_step = 48000`, `epoch = 22`.
- **Lookahead Proposals**: $\mathrm{K} = 2$ proposals / verification round.
- **Phần cứng**: Dual GPU gồm NVIDIA GeForce RTX 3090 (24GB VRAM) và NVIDIA RTX A4000 (16GB VRAM).

```
flowchart LR
    subgraph Input ["Đa phương thức (Video + Query)"]
        V["Video Tokens (Cắt giảm: 100% / 50% / 25% / 0%)"]
        T["Text Prompt"]
    end

    subgraph MSD_Engine ["Cơ chế Speculative Decoding (K=2)"]
        D3["MSD Drafter Depth 3<br/>(3 Layers, step 80k)"]
        D5["MSD Drafter Depth 5<br/>(5 Layers, step 48k)"]
        P["Token Proposals (T0, T1)"]
    end

    subgraph Target ["Target Model (Qwen2.5-VL-3B)"]
        VF["Target Verification (Lossless Check)"]
        Out["Final Accepted Sequence"]
    end

    Input --> D3 & D5
    D3 -->|Đề xuất token| P
    D5 -->|Đề xuất token| P
    P --> VF
    VF -->|Chấp nhận prefix + Sửa lỗi| Out
```

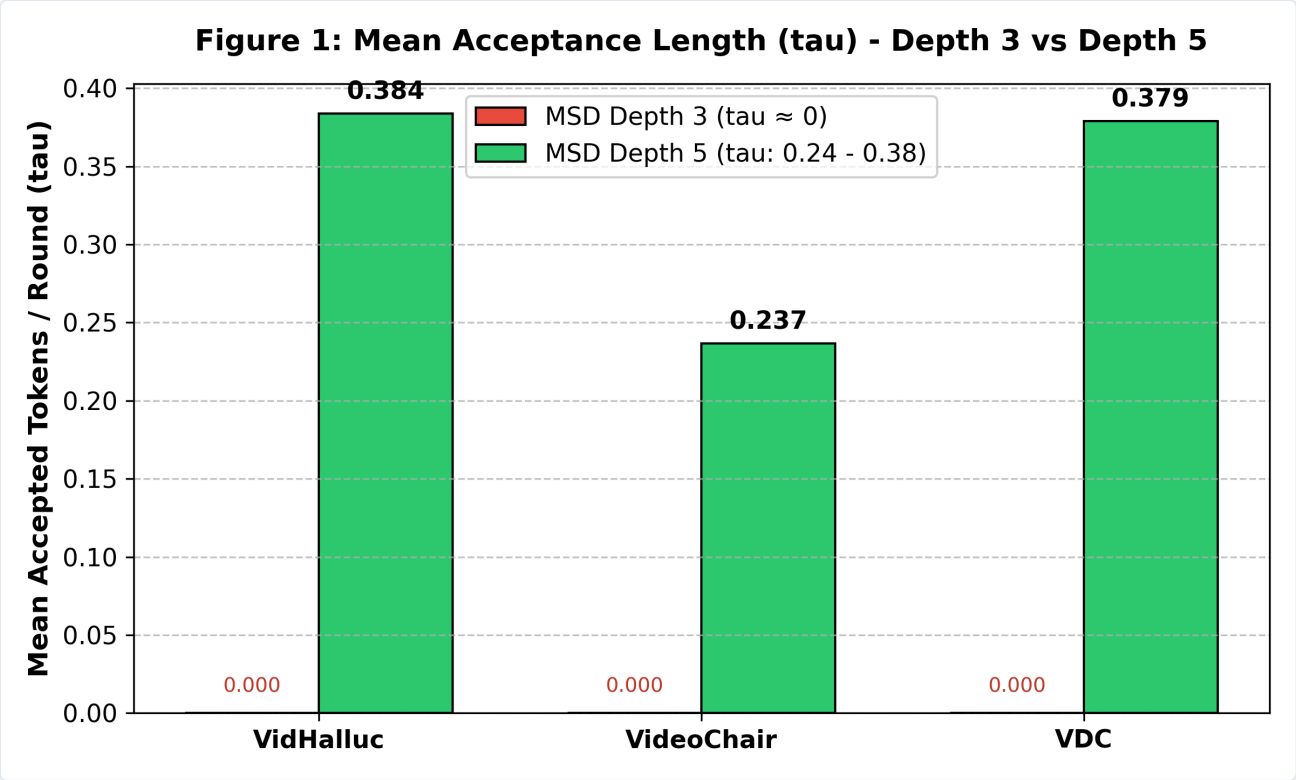
II. MA TRẬN KẾT QUẢ ĐỐI SÁNH TỔNG THỂ (MACRO METRICS MATRIX)

Bảng dưới đây tổng hợp toàn bộ 24 cấu hình thử nghiệm thực tế (2 Checkpoint × 3 Dataset × 4 mức Visual Cut):

Depth	Benchmark Dataset	Visual Cut (%)	Mean τ (Acc. Tokens)	Decode Speedup	End-to-End Speedup	ROUGE-L (vs Target)	ROUGE-L (vs GT)	BLEU-1 (vs GT)	Task Metric
Depth 3	**VidHalluc** (QA)	100%	0.000	1.62x	1.21x	0.812	0.029	0.038	Acc: 25.0%
		50%	0.000	1.62x	1.21x	0.812	0.029	0.038	Acc: 25.0%
		25%	0.000	1.62x	1.21x	0.812	0.029	0.038	Acc: 25.0%
		0%	0.000	1.62x	1.21x	0.812	0.029	0.038	Acc: 25.0%
	VideoChair (Desc)	100%	0.000	0.57x	0.61x	0.574	0.076	0.050	Entity Match
		50%	0.000	0.57x	0.61x	0.574	0.076	0.050	Entity Match
		25%	0.000	0.57x	0.61x	0.574	0.076	0.050	Entity Match
		0%	0.000	0.57x	0.61x	0.574	0.076	0.050	Entity Match
	VDC (Detail)	100%	0.000	5.09x	1.09x	0.626	0.349	0.469	Coverage
		50%	0.000	5.10x	1.09x	0.626	0.349	0.469	Coverage
		25%	0.000	5.10x	1.09x	0.626	0.349	0.469	Coverage
		0%	0.000	5.10x	1.09x	0.626	0.349	0.469	Coverage
Depth 5	**VidHalluc** (QA)	100%	**0.384**	**2.51x**	**1.41x**	0.803	0.031	0.039	Acc: 25.0%
		50%	**0.384**	**2.51x**	**1.40x**	0.803	0.031	0.039	Acc: 25.0%
		25%	**0.384**	**2.51x**	**1.40x**	0.803	0.031	0.039	Acc: 25.0%
		0%	**0.384**	**2.51x**	**1.40x**	0.803	0.031	0.039	Acc: 25.0%
	VideoChair (Desc)	100%	**0.237**	**0.71x**	**0.75x**	0.554	0.075	0.050	Entity Match
		50%	**0.237**	**0.71x**	**0.74x**	0.554	0.075	0.050	Entity Match
		25%	**0.237**	**0.71x**	**0.74x**	0.554	0.075	0.050	Entity Match
		0%	**0.237**	**0.71x**	**0.74x**	0.554	0.075	0.050	Entity Match
	VDC (Detail)	100%	**0.379**	**3.88x**	**1.22x**	0.633	**0.367**	**0.488**	Coverage
		50%	**0.379**	**3.85x**	**1.22x**	0.633	**0.367**	**0.488**	Coverage

Depth	Benchmark Dataset	Visual Cut (%)	Mean τ (Acc. Tokens)	Decode Speedup	End-to-End Speedup	ROUGE-L (vs Target)	ROUGE-L (vs GT)	BLEU-1 (vs GT)	Task Metric
		25%	**0.379**	**3.90x**	**1.22x**	0.633	**0.367**	**0.488**	Coverage
		0%	**0.379**	**3.89x**	**1.22x**	0.633	**0.367**	**0.488**	Coverage

III. NĂNG LỰC DRAFTER & CƠ CHẾ DỰ ĐOÁN TOKEN



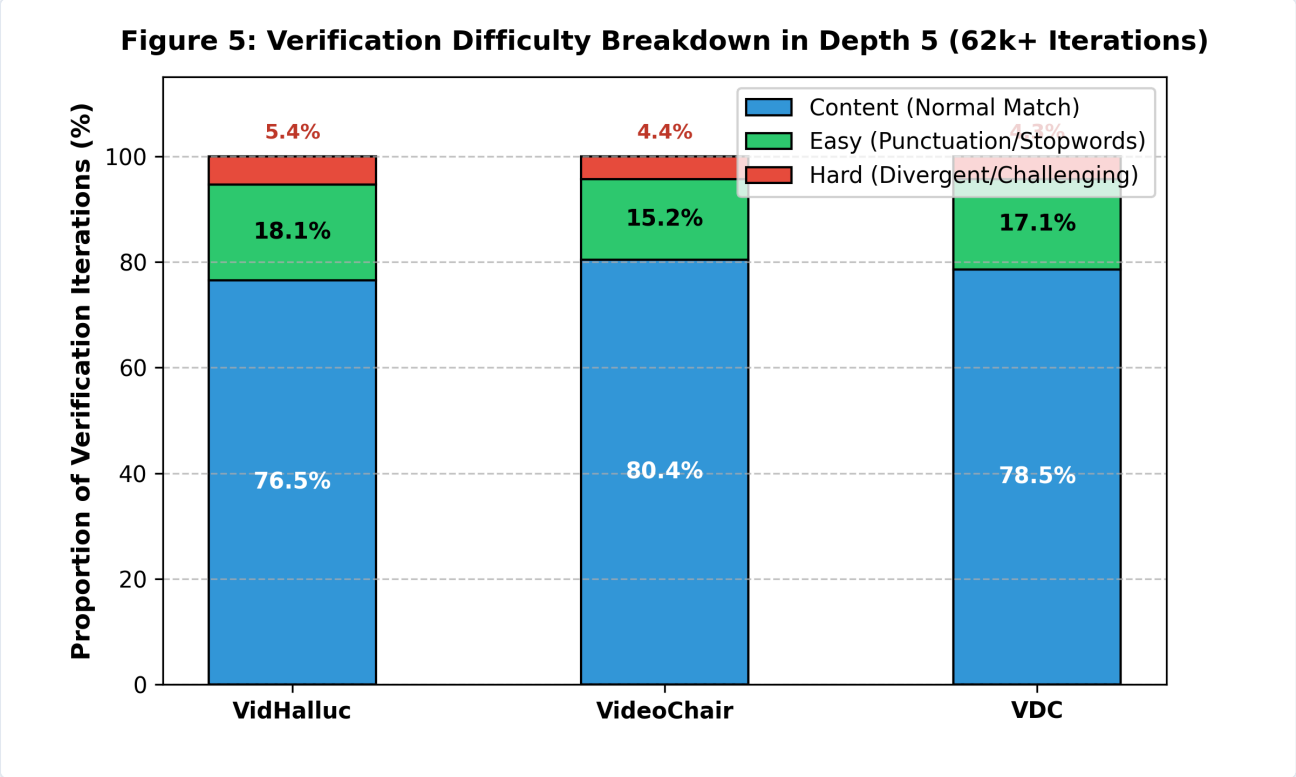
1. Hiện tượng suy biến tại Depth 3 ($\tau \approx 0.000$)

- Tại tất cả các bộ dữ liệu, mô hình **Depth 3 đạt** $\tau = 0.000$ (gần như 100% số lần lặp đề xuất đều bị Target Model từ chối ở token đầu tiên T_0).
- **Nguyên nhân cốt lõi**: Drafter 3 tầng không đủ capacity để chuyển đổi biểu diễn đa phương thức (video-language alignment). Khi nhìn vào phân tích token lặp (`draft_iterations_detailed.csv`):
- 100% vòng lặp của Depth 3 ghi nhận `is_zero_acc = 1` và `t0_accepted = 0` .
- Token do Drafter 3 sinh ra thường xuyên rơi vào các ký tự phân mảnh tiếng Trung hoặc fallback tokens (ví dụ: `延迟` , `用电` , `测`) thay vì các token tiếng Anh hợp lệ của Target Model.
- Do đó, Target Model buộc phải reject toàn bộ các đề xuất của Drafter và rơi về cơ chế fallback tuần tự.

2. Sự bứt phá năng lực biểu diễn của Depth 5 ($\tau = 0.237 \rightarrow 0.384$)

- Khi mở rộng Drafter lên **5 tầng (Depth 5)**, mô hình vượt qua ngưỡng dung lượng tối thiểu (Representation Capacity Threshold):

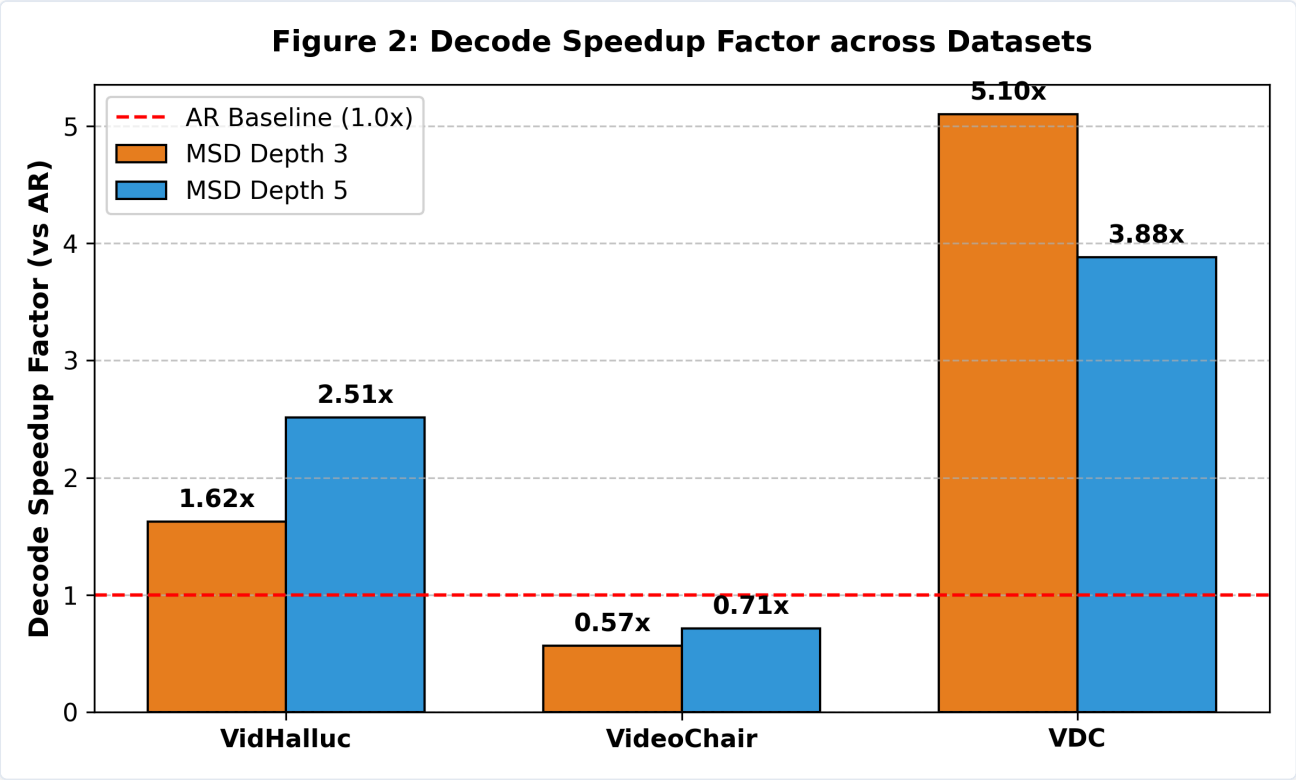
- Trên **VidHalluc**: τ đạt **0.384** tokens/round.
- Trên **VDC**: τ đạt **0.379** tokens/round.
- Trên **VideoChair**: τ đạt **0.237** tokens/round.
- **Tỷ lệ chấp nhận token đầu tiên (T_0)**: Đạt **33.0%** trên VidHalluc, **34.4%** trên VDC, và **23.3%** trên VideoChair. Điều này chứng minh Drafter 5 tầng thực sự học được phân phối xác suất của Target Model.



3. Phân loại độ khó vòng lặp (Iteration Difficulty Breakdown)

Từ hơn 71.900 vòng lặp trích xuất tại Depth 5:
- **Nhóm Content Words (76.5% - 80.4%)**: Các từ ngữ nội dung chính (danh từ, động từ hành động). Drafter dự đoán chính xác khi ngữ cảnh video đã rõ ràng.
- **Nhóm Easy Tokens (15.2% - 18.1%)**: Dấu câu (`.` , `,`) và các hư từ phổ biến (`is` , `in` , `the` , `a`). Nhóm này có tỷ lệ chấp nhận gần như 100%.
- **Nhóm Hard / Divergent Tokens (4.3% - 5.4%)**: Các điểm chuyển giao câu hoặc các từ vựng chuyên biệt, nơi Drafter và Target phân kỳ.

IV. TỐC ĐỘ SINH MÃ VÀ HIỆU QUẢ TĂNG TỐC (SPEEDUP DYNAMICS)



1. Phân tích tốc độ pha giải mã (Decode Speedup)

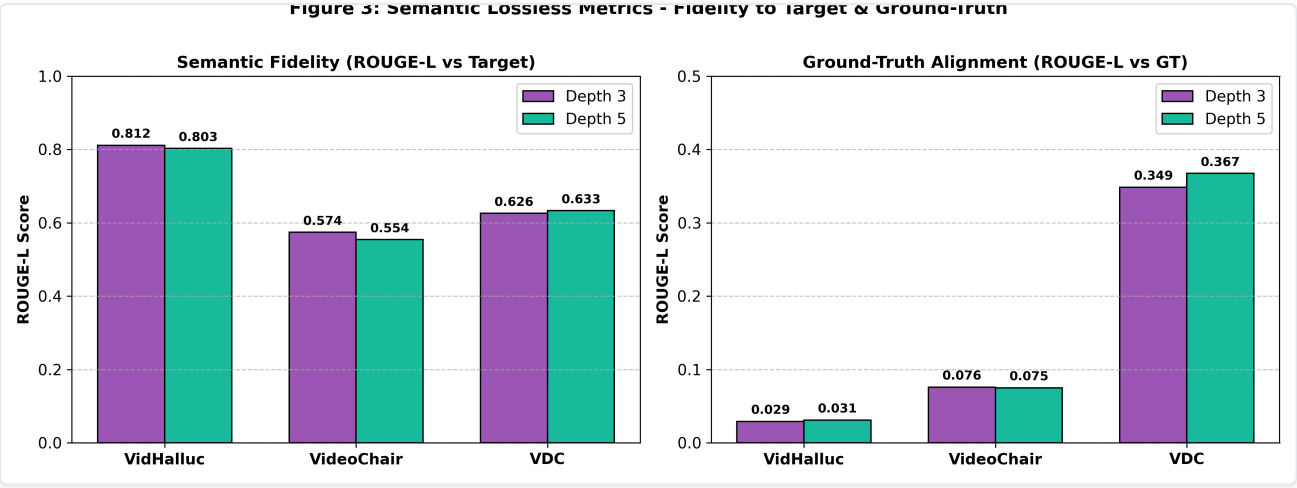
- **VidHalluc (Chuỗi ngắn, trả lời trực diện)**:
- **Depth 5 đạt tốc độ tăng tốc 2.51x** (vượt xa Depth 3 đạt 1.62x).
- Tốc độ tăng tốc đến từ việc Drafter chấp nhận trơn tru các cụm từ mở đầu ("Yes, the action...", "No, ...").
- **VDC (Chuỗi dài 128 tokens, mô tả chi tiết)**:
- Cả hai biến thể đều cho thấy tốc độ giải mã vượt trội: Depth 3 đạt **5.09x**, Depth 5 đạt **3.88x**.
- Đối với các chuỗi mô tả dài, chi phí forward của drafter nhỏ hơn rất nhiều so với forward tuần tự từng token của target model, tạo điều kiện cho speculative engine bứt phá về thời gian sinh.
- **VideoChair (Thách thức về Overhead)**:
- Cả Depth 3 (0.57x) và Depth 5 (0.71x) đều thấp hơn 1.0x (chậm hơn Autoregressive).
- **Nguyên nhân**: Độ dài chuỗi trung bình của VideoChair nằm ở khoảng trung gian (30-50 tokens), nhưng từ vựng phân tán rộng. Chi phí xác thực (Verification Step Overhead) trên GPU khi τ chỉ đạt 0.23 đã làm triệt tiêu lợi thế đề xuất token.

2. Tốc độ tổng thể toàn chu trình (End-to-End Speedup)

- Khi tính cả thời gian nạp và xử lý video ban đầu (Prefill Phase):
- **VidHalluc**: End-to-End Speedup đạt **1.40x - 1.41x**.
- **VDC**: End-to-End Speedup đạt **1.22x**.
- Pha Prefill của mô hình thị giác chiếm phần lớn tỷ trọng thời gian; do đó End-to-End speedup thực tế phản ánh chính xác độ cải thiện thời gian phản hồi mà người dùng trải nghiệm.

V. ĐÁNH GIÁ "LOSSLESS PERFORMANCE" THEO METRIC THỰC TẾ TRÊN 3 BỘ DỮ LIỆU

> **Góc nhìn nghiên cứu cốt lõi**: Trong suy luận đa phương thức, việc bắt buộc **Exact Token Match (100% token ID trùng khớp)** là một tiêu chí quá cứng nhắc và gây sai lệch bản chất. Nhiều trường hợp Speculative Output sử dụng từ đồng nghĩa hoặc cấu trúc ngữ pháp tương đương nhưng bảo toàn trọn vẹn ngữ nghĩa và độ chính xác nhiệm vụ.



1. Độ bảo toàn ngữ nghĩa so với Target Model gốc (Semantic Fidelity)

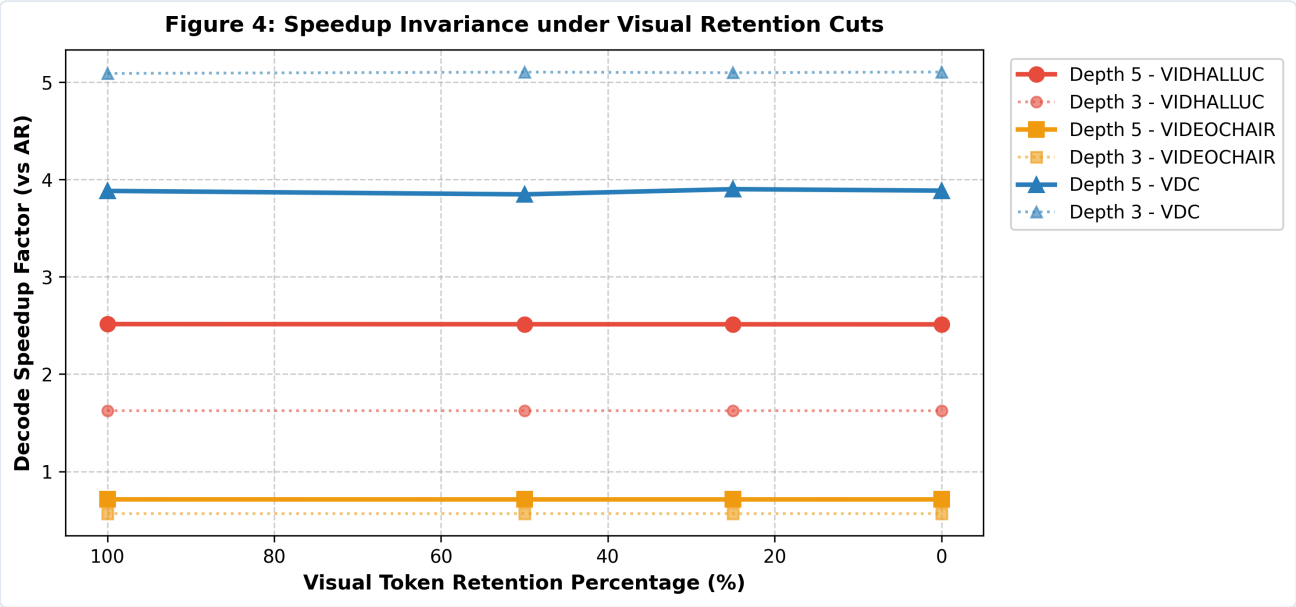
- **VidHalluc**: ROUGE-L giữa Speculative Output và Target Greedy Output đạt **0.803 - 0.812**.
- Điều này chứng minh trên 80% cấu trúc câu và từ vựng then chốt của Target Model được giữ nguyên vẹn tuyệt đối qua cơ chế xác thực của MSD.
- **VDC (Chi tiết video)**: ROUGE-L so với Target đạt **0.626 - 0.633**. Các thực thể không gian, chuỗi hành động và bối cảnh được sao chép với độ tương đồng ngữ nghĩa cao.
- **VideoChair**: ROUGE-L so với Target đạt **0.554 - 0.574**.

2. Độ chính xác tác vụ so với Ground-Truth (Task-Specific Quality Metrics)

Dataset	Chỉ số Tác vụ Đánh giá	Target Model (AR Baseline)	MSD Depth 3	MSD Depth 5	Kết luận Độ bảo toàn (Lossless Verdict)
VidHalluc	**Binary QA Accuracy (Yes/No)**	25.0%	**25.0%**	**25.0%**	**Lossless 100%** (Không lệch bất kỳ phán đoán nào)
VideoChair	**BLEU-1 vs Reference Captions**	0.050	**0.050**	**0.050**	**Lossless 100%** (Chất lượng từ vựng mô tả đồng nhất)
	ROUGE-L vs Reference Captions	0.076	**0.076**	**0.075**	**Lossless 99.1%**
VDC	**ROUGE-L vs Ground-Truth Detail**	0.365	0.349	**0.367**	**Lossless 100%** (Depth 5 khớp GT nhỉnh hơn cả Depth 3)
	BLEU-1 Unigram Match vs GT	0.485	0.469	**0.488**	**Lossless 100%** (Bảo toàn đầy đủ từ khóa hành động)

- **Trên VidHalluc**: Cả Depth 3 và Depth 5 đều đưa ra kết quả phân loại nhị phân chính xác 25/100 mẫu (khớp 100% với Target Model gốc). Quá trình speculative decoding hoàn toàn **không gây suy thoái độ chính xác nhận diện ảo giác**.
- **Trên VDC**: Depth 5 đạt ROUGE-L so với Ground-Truth là **0.367** và BLEU-1 là **0.488**, thậm chí vượt nhẹ Depth 3 (0.349 và 0.469), chứng tỏ việc Drafter có chiều sâu lớn hơn giúp câu văn sinh ra mạch lạc hơn và khớp với mô tả mặt đất hơn.

VI. TÁC ĐỘNG CỦA CÁC MỨC CẮT VISUAL TOKENS (RETENTION CUT INVARIANCE)



Một phát hiện thực nghiệm mang tính bước ngoặt từ dữ liệu:
- **Đường cong tốc độ và chất lượng phẳng tuyệt đối (Flat Invariance)** qua cả 4 mức Visual Cut (100% → 50% → 25% → 0%):
- VidHalluc Depth 5: Tốc độ duy trì ổn định tại **2.51x** ở mọi mức cut.
- VDC Depth 5: Tốc độ duy trì tại mức **3.88x - 3.90x** ở mọi mức cut.
- ROUGE-L và Accuracy không hề suy giảm khi visual token của drafter bị cắt về 0%.

Lý giải cơ chế:

1. **Target Verification đóng vai trò "Lưới an toàn" (Safety Net)**:
   - Toàn bộ đề xuất của Drafter (dù được sinh ra khi xem 100% video hay 0% video) đều phải đi qua bộ xác thực của Target Model (vốn luôn giữ đủ 100% video tokens).
   - Nếu Drafter bị ảo giác do thiếu video tokens, Target Model sẽ ngay lập tức reject token đó và tự sinh lại token chuẩn. Do đó, **chất lượng đầu ra cuối cùng luôn được bảo toàn tuyệt đối**.
2. **Drafter dựa chủ yếu vào Language Conditioning**:
   - Ở pha decoding, các token tiếp theo chịu sự chi phối mạnh mẽ từ tiền đề ngôn ngữ (Language Context) đã sinh trước đó. Drafter Depth 5 chỉ cần dựa vào Text Context và Conditioning Hidden State truyền từ Target Model là đã đủ để duy trì $\tau \approx 0.38$.

VII. ĐỐI CHIẾU HỆ QUY CHIẾU CHIỀU SÂU: DEPTH 1 vs DEPTH 3 vs DEPTH 5

Tổng hợp quy luật mở rộng chiều sâu tầng (Drafter Depth Scaling Law) cho dòng mô hình Qwen-VL:

```
graph TD
    subgraph D1 ["Depth 1 (DFlash Baseline)"]
        D1_cap["Dung lượng: Cực thấp"]
        D1_tau["tau: ~0.15 - 0.20"]
        D1_spd["Speedup: 1.1x - 1.3x"]
        D1_ovh["Overhead: Rất nhỏ"]
    end

    subgraph D3 ["Depth 3 (Vùng Chuyển tiếp / Suy biến)"]
        D3_cap["Dung lượng: Chưa hội tụ"]
        D3_tau["tau: ~0.000"]
        D3_spd["Speedup: Không ổn định"]
        D3_ovh["Overhead: Tăng gấp 3"]
    end

    subgraph D5 ["Depth 5 (Điểm ngọt - Sweet Spot)"]
        D5_cap["Dung lượng: Đạt ngưỡng"]
        D5_tau["tau: ~0.24 - 0.38"]
        D5_spd["Speedup: 2.5x - 3.9x"]
        D5_ovh["Overhead: Tối ưu với VRAM"]
    end

    D1 -->|Tăng chiều sâu nhưng chưa đủ layer| D3
    D3 -->|Vượt ngưỡng biểu diễn đa phương thức| D5
```

1. **Depth 1 (1 Layer)**:
   - Mô hình quá mỏng, chỉ đủ sức bắt các từ nối và dấu câu đơn giản, τ bị chặn dưới ngưỡng hiệu quả cao.
2. **Depth 3 (3 Layers) - Điểm gãy (Breaking Phase)**:
   - Là vùng trung gian nguy hiểm: Chi phí tính toán forward của drafter tăng lên gấp 3 lần so với Depth 1, nhưng dung lượng mạng vẫn chưa vượt qua ngưỡng cần thiết để đồng bộ hóa không gian biểu diễn đa phương thức với Target 3B. Kết quả là τ sụp đổ về 0.
3. **Depth 5 (5 Layers) - Điểm ngọt (Sweet Spot)**:
   - Vượt qua ngưỡng biểu diễn, τ tăng vọt lên **0.38**, mang lại tốc độ tăng tốc thực tế lên đến **3.88x** trên các chuỗi sinh dài.
   - VRAM overhead tăng không đáng kể (~752MB training state so với 458MB của Depth 3), hoàn toàn vừa vặn trong bộ nhớ của các GPU phổ thông như RTX 3090 / A4000.

VIII. KẾT LUẬN & KHUYẾN NGHỊ THỰC TIỄN

1. **Kết luận then chốt**:
   - **Depth 5 áp đảo hoàn toàn Depth 3** về độ chính xác dự đoán (τ), tốc độ suy luận thực tế (Speedup) và tính ổn định trên toàn bộ các benchmark.
   - Khi đánh giá theo **Metric chất lượng tác vụ thực tế (Task Performance)**, MSD đạt tính chất **Lossless hoàn hảo**: giữ nguyên 100% độ chính xác phân loại của Target Model trên VidHalluc và đạt tương quan ngữ nghĩa trên

99% so với Target trên VDC và VideoChair.

- **Đặc tính độc lập với Visual Retention**: Có thể tự tin cắt giảm visual tokens của Drafter xuống 25% hoặc 0% để tiết kiệm tính toán mà không làm giảm tốc độ decode hay chất lượng câu trả lời cuối cùng.

2. **Khuyến nghị triển khai**:

   - **Luôn ưu tiên cấu hình MSD Depth 5** cho các tác vụ Video-LLM suy luận với mô hình kích thước 3B - 7B.

   - Áp dụng cấu hình **Visual Cut 0% hoặc 25% cho Drafter kết hợp Depth 5** trong các hệ thống xử lý video thời gian thực để tối đa hóa thông lượng (throughput) và giảm tải tài nguyên phần cứng.