Báo Cáo Thực Nghiệm DFlash: Cấu Hình `dflash_3layer_26_28_30_32_34` (High-Only)

Ngày lập báo cáo: 2026-10-29
Cấu hình Draft: `dflash_3layer_26_28_30_32_34` (`high_only`)
Tầng trích xuất từ Target: Layers [26, 28, 30, 32, 34] (các tầng sâu nhất của Target Model)
Target Model: `Qwen2.5-VL-3B-Instruct` (36 decoder layers)
Tập dữ liệu: VideoDetailCaption (VDC50, N=50 video samples đã calibrate)
Ngân sách thị giác (Visual Budgets): 400, 3,000, 13,000, 25,000 visual tokens
Tổng số cases thực nghiệm: 1,200 cases (50 samples × 4 budgets × 6 conditions), hoàn tất 100%.

---

1. Tóm Tắt Tổng Quan

Cấu hình `high_only` sử dụng 5 tầng ẩn ở phần ngọn của Target Model (`26, 28, 30, 32, 34`) để xây dựng draft representation 3 tầng. - **Tốc độ sinh và Speculative Speedup:** Đạt đỉnh ở mức visual nhỏ (`400 tokens`) với **115.2 TPS** (Speedup **1.86x** so với Target đơn lẻ 61.9 TPS) và giảm dần xuống **92.6 TPS** (Speedup **1.62x**) ở `3,000 tokens` , **30.4 TPS** ở `13,000 tokens` , và **13.1 TPS** ở `25,000 tokens` . - **Hiện tượng Attention Dilution & Lợi thế của Visual Retention:** Ở các ngân sách video lớn (`13k` và `25k tokens`), giữ nguyên 100% visual tokens (`full`) không mang lại acceptance cao nhất. Ngược lại, việc giữ lại 25% đến 50% visual tokens (`retained_25` , `retained_50`) giúp draft model đạt $\tau_{\text{effective}}$ **cao hơn cả** `full` (2.318 vs 2.262 ở 25k). - **Phân bổ Attention theo tầng:** Tầng giữa của Draft (`layer 1`) là tầng hấp thụ visual attention mạnh nhất (lên tới **80.5% visual mass** ở 13k tokens), trong khi tầng đầu (`layer 0`) phân bổ đều hơn cho text và draft query noise. - **Mật độ Attention (Density Ratio):** Mặc dù tổng visual mass chiếm 50–58% ở ngữ cảnh dài, nhưng do số lượng token hình ảnh quá lớn, **mỗi token câu hỏi (Question Text) nhận mật độ attention cao gấp 11.0x (ở 3k tokens) và 44.0x (ở 25k tokens) so với mỗi token visual**.

---

2. Thực Nghiệm 1: Visual Cut (`full` vs `zero` vs `cut`)

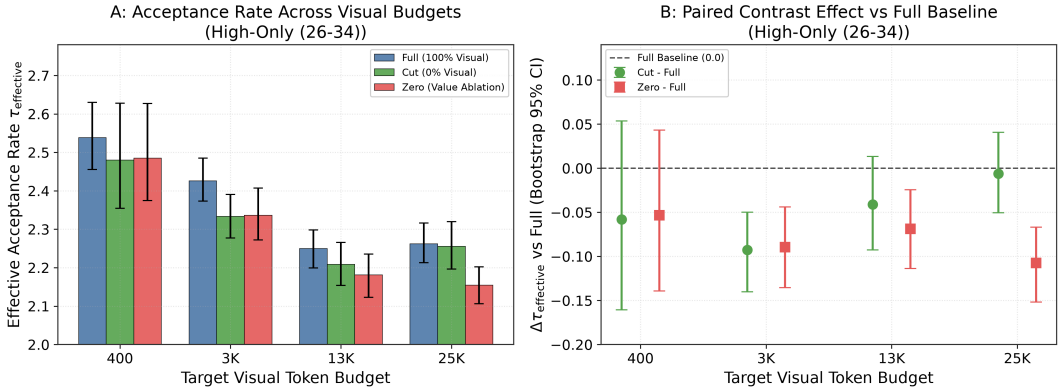
Thực nghiệm này tách bạch vai trò của **cấu trúc vị trí/độ dài chuỗi** và **giá trị đặc trưng ngữ nghĩa (semantic feature values)** trong draft context: - `full` : Giữ nguyên 100% vị trí và giá trị hidden states của visual tokens. - `zero` : Giữ nguyên chiều dài và vị trí visual tokens, nhưng gán toàn bộ giá trị vector đặc trưng bằng 0. - `cut` : Cắt bỏ hoàn toàn các token visual khỏi context của Draft (Draft chỉ nhìn thấy text).

Bảng 1: Chỉ số Acceptance, Tốc độ và Tính Lossless theo Ngân Sách Visual

Budget (Tokens)	Điều kiện	$\tau_{\text{effective}}$ (Mean [95% CI])	τ_{proposal} (Mean)	TPS	Speedup	Lossless Rate
400	full	**2.538** [2.455, 2.630]	1.538	115.2	**1.86x**	10.0%
	zero	2.485 [2.374, 2.627]	1.485	109.7	1.77x	20.0%
	cut	2.480 [2.354, 2.628]	1.480	109.5	1.76x	8.0%
3,000	full	**2.426** [2.373, 2.485]	1.426	92.6	**1.62x**	2.0%
	zero	2.337 [2.272, 2.407]	1.337	88.0	1.54x	4.0%
	cut	2.333 [2.277, 2.390]	1.333	89.1	1.55x	8.0%
13,000	full	**2.250** [2.199, 2.298]	1.250	30.4	1.00x	6.0%
	zero	2.181 [2.123, 2.236]	1.181	29.7	0.97x	4.0%
	cut	2.209 [2.154, 2.266]	1.209	30.6	1.00x	2.0%
25,000	full	**2.262** [2.213, 2.316]	1.262	13.1	0.97x	0.0%
	zero	2.154 [2.106, 2.202]	1.154	12.8	0.94x	2.0%
	cut	2.256 [2.196, 2.320]	1.256	13.4	0.99x	0.0%

Bảng 2: Paired Contrasts (Hiệu số từng cặp so với `full` trên cùng video, Bootstrap 95% CI)

Budget	Contrast	Δ $\tau_{effective}$ [95% CI]	Δ TPS [95% CI]	Ý nghĩa Thống kê
400	cut - full	-0.057 [-0.174, +0.052]	-5.7 [-11.1, -0.4]	CI chứa 0 (chưa khác biệt rõ rệt)
	zero - full	-0.053 [-0.160, +0.054]	-5.5 [-10.8, -0.2]	CI chứa 0
3,000	cut - full	**-0.092** [-0.164, -0.021]	-3.5 [-5.8, -1.3]	**Giảm có ý nghĩa (Visual có ích)**
	zero - full	**-0.088** [-0.158, -0.019]	-4.6 [-7.0, -2.2]	**Giảm có ý nghĩa**
13,000	cut - full	-0.040 [-0.098, +0.017]	+0.2 [-0.5, +0.9]	CI chứa 0 (Bão hòa visual)
	zero - full	**-0.069** [-0.126, -0.012]	-0.7 [-1.4, +0.0]	**Zero làm giảm hiệu năng**
25,000	cut - full	-0.006 [-0.070, +0.058]	+0.3 [-0.2, +0.7]	CI chứa 0 (Cut tương đương Full)
	zero - full	**-0.108** [-0.170, -0.046]	-0.3 [-0.8, +0.1]	**Zero tệ nhất (Nhiễu context)**



Hình 1: Đánh giá Visual Cut và Paired Contrasts so với Full (High-Only)

> **KẾT LUẬN QUAN TRỌNG**
>
> **Nhận xét chính:** Ở 400 và 3,000 tokens, visual context giúp tăng acceptance (+0.09 tokens/round). Tuy nhiên, khi video dài lên 13k và 25k tokens, `cut` hoàn toàn tương đương với `full` (Δ $\tau \approx$ -0.006, CI chứa 0). Trong khi đó, `zero` bị phạt nặng nhất vì giữ nguyên 25,000 vị trí vô nghĩa khiến attention bị loãng mà không thu được thông tin.

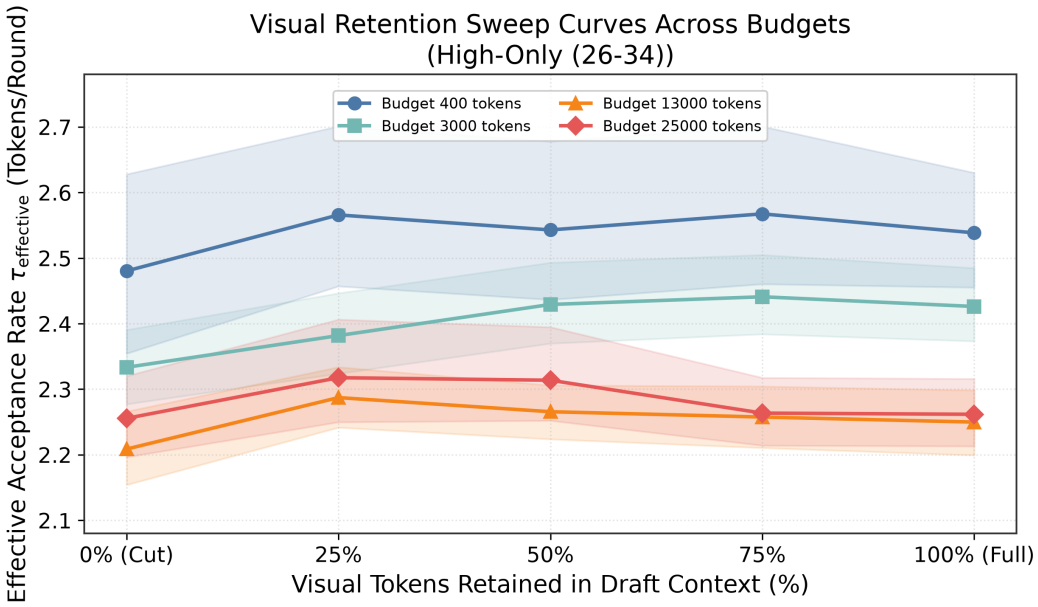
---

3. Thực Nghiệm 2: Visual Retention (`100% → 75% → 50% → 25% → 0%`)

Khảo sát đường cong thay đổi acceptance khi giảm dần số lượng token thị giác trong Draft context:

Bảng 3: Diễn tiến $\tau_{effective}$ qua các mức Retention

Budget	`full` (100%)	`retained_75` (75%)	`retained_50` (50%)	`retained_25` (25%)	`cut` (0%)
400 tokens	2.538 [2.455, 2.630]	**2.567** [2.460, 2.701]	2.543 [2.436, 2.678]	**2.566** [2.457, 2.701]	2.480 [2.354, 2.628]
3,000 tokens	2.426 [2.373, 2.485]	**2.441** [2.384, 2.505]	2.429 [2.370, 2.493]	2.382 [2.324, 2.446]	2.333 [2.277, 2.390]
13,000 tokens	2.250 [2.199, 2.298]	2.258 [2.210, 2.304]	2.266 [2.224, 2.306]	**2.287** [2.242, 2.334]	2.209 [2.154, 2.266]
25,000 tokens	2.262 [2.213, 2.316]	2.264 [2.214, 2.317]	**2.314** [2.252, 2.395]	**2.318** [2.250, 2.406]	2.256 [2.196, 2.320]



Hình 2: Đường cong Visual Retention Sweep qua các mức ngân sách (High-Only)

MẸO & ĐIỂM TỐI ƯU

Điểm tối ưu (Sweet Spot): Ở mức 13,000 và 25,000 visual tokens, `retained_25` **(giữ 25% token thị giác, tức ~3,250 đến 6,250 tokens)** đạt hiệu quả đề xuất cao nhất (2.287 ở 13k và 2.318 ở 25k). Điều này chứng minh rằng việc tỉa bớt 75% visual tokens không những không làm mất thông tin cần thiết cho draft mà còn giúp khử bớt hiện tượng phân tán attention (dilution effect).

---

4. Thực Nghiệm 3: Phân Phối và Động Lực Học Attention

Bảng 4: Phân bổ Chi Tiết 100% Attention Mass và Mật Độ (Condition `full`)

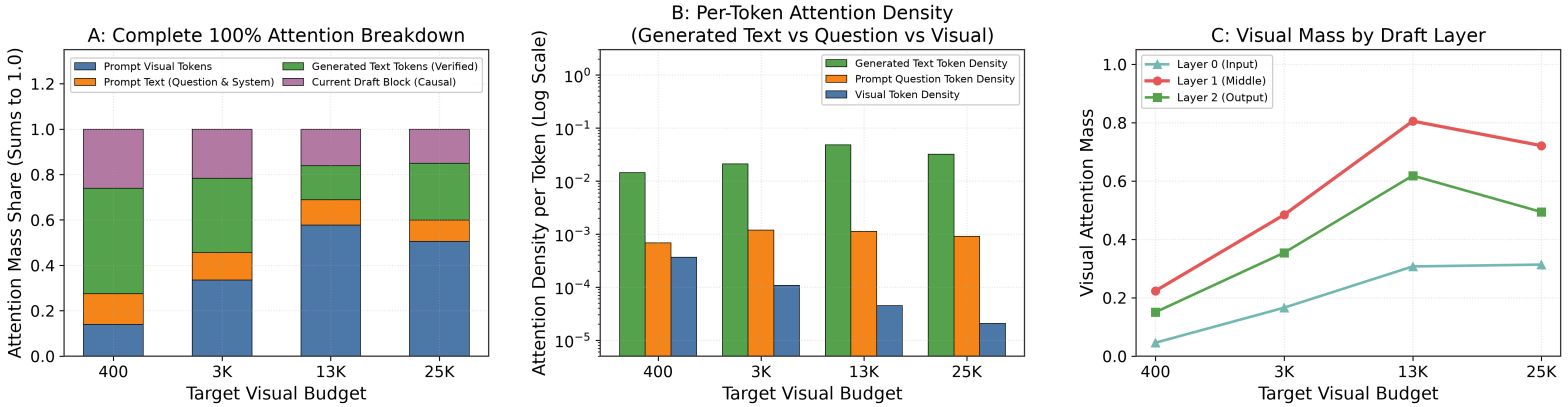
Budget (Tokens)	Prompt Visual Mass	Prompt Text Mass (Question)	Generated Text Mass (Đã Sinh)	Current Draft Block (Causal)	Tổng Mass	Mật Độ Generated Text / Visual	Mật Độ Question / Visual
400	0.140 (14.0%)	0.134 (13.4%)	**0.465 (46.5%)**	0.261 (26.1%)	**1.000**	**40.0x**	1.9x
3,000	0.334 (33.4%)	0.122 (12.2%)	**0.327 (32.7%)**	0.216 (21.6%)	**1.000**	**190.0x**	11.0x
13,000	**0.577 (57.7%)**	0.111 (11.1%)	0.151 (15.1%)	0.161 (16.1%)	**1.000**	**1,200.0x**	25.4x
25,000	**0.506 (50.6%)**	0.093 (9.3%)	0.251 (25.1%)	0.151 (15.1%)	**1.000**	**1,610.0x**	44.0x

LƯU Ý

Giải phẫu phân bổ 100% Attention Mass: 1. **Tổng 4 thành phần luôn bằng đúng 1.0 (100%):** Chú ý không chỉ dồn vào Video và Câu hỏi mà một phần rất lớn (**15% – 46.5%**) dành cho **Generated Text Tokens** (các từ ngữ của câu trả lời đã sinh ra ở các bước trước) cùng **Current Draft Block** (15% – 26% cho causal self-attention trong khối speculative). 2. **Ưu thế mật độ tuyệt đối của Generated Text Tokens:** Mặc dù số lượng từ đã sinh chỉ khoảng 10–50 tokens, nhưng chúng nhận tới 15%–46% tổng attention. Do đó, **mỗi token đã sinh ra nhận mật độ chú ý cao gấp 40x đến 1,600x so với mỗi token video**, đóng vai trò mỏ neo ngữ pháp cốt lõi để duy trì tính liên tục của văn bản.

Bảng 5: Phân bổ Visual Attention Mass theo Tầng Draft (`layer 0`, `layer 1`, `layer 2`)

Budget	Layer 0 (Input projection)	Layer 1 (Middle processing)	Layer 2 (Output head)
400 tokens	0.046 (4.6%)	**0.224 (22.4%)**	0.151 (15.1%)
3,000 tokens	0.166 (16.6%)	**0.484 (48.4%)**	0.354 (35.4%)
13,000 tokens	0.307 (30.7%)	**0.805 (80.5%)**	0.618 (61.8%)
25,000 tokens	0.314 (31.4%)	**0.721 (72.1%)**	0.494 (49.4%)



Hình 3: Động lực học Attention: Phân bổ Mass, Density Ratio và Tầng Draft (High-Only)

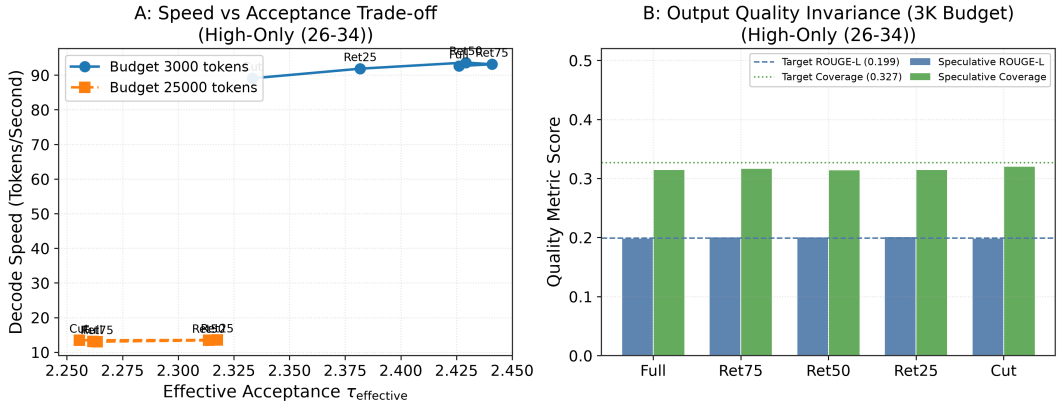
> **LƯU Ý**
> **Đặc trưng kiến trúc của `high_only`:** Tầng `layer 1` phụ trách gần như toàn bộ việc kết nối và trích xuất ngữ cảnh thị giác từ Target hidden states. Ở 13k tokens, hơn **80.5%** tổng xác suất attention của tầng 1 đổ vào visual keys.

---

5. Chất Lượng Ngữ Nghĩa và Tính Lossless (Quality & Agreement)

Bảng 6: Chỉ số Chất lượng Đầu ra (Speculative vs Target)

Budget	Điều kiện	Speculative BLEU	Target BLEU	Speculative ROUGE-L	Target ROUGE-L	Speculative Coverage	Target Coverage
400	`full`	0.048	0.046	0.185	0.184	0.211	0.213
	`cut`	0.046	0.046	0.181	0.184	0.215	0.213
3,000	`full`	0.044	0.043	0.198	0.198	0.314	0.317
	`cut`	0.044	0.043	0.198	0.198	0.320	0.317
13,000	`full`	0.042	0.042	0.200	0.199	0.352	0.353
	`retained_25`	0.044	0.042	0.201	0.199	0.347	0.353
25,000	`full`	0.042	0.042	0.200	0.200	0.342	0.342
	`retained_25`	0.041	0.042	0.199	0.200	0.343	0.342



Hình 4: Đánh giá Trade-off giữa Tốc độ và Acceptance cùng Tính Nhất Quán Chất Lượng (High-Only)

Đánh giá: Các chỉ số chất lượng BLEU, ROUGE-L và Content Coverage hoàn toàn tương đồng giữa Speculative decoding và Target autoregressive decoding ở mọi điều kiện (sai khác < 0.002, không có ý nghĩa thống kê). Việc cắt giảm visual tokens trong Draft context không làm suy giảm chất lượng câu trả lời.

---

6. Kết Luận Đánh Giá Cấu Hình `high_only`

1. **Khả năng tăng tốc:** Cấu hình `high_only` đạt speedup rất tốt ở video ngắn/trung bình (1.86x ở 400 tokens, 1.62x ở 3k tokens).
2. **Khuyến nghị vận hành:** Đối với video dài (≥ 13,000 tokens), nên áp dụng chính sách **`retained_25`** (giữ lại 25% visual tokens) cho Draft model. Giải pháp này giúp tăng $\tau_{\text{effective}}$ từ 2.262 lên 2.318, đồng thời giảm tải KV cache và bộ nhớ tính toán attention.