Báo Cáo Thực Nghiệm DFlash: Cấu Hình `dflash_3layer_17_19_25_33_34` (Middle-High)

Ngày lập báo cáo: 2026-10-29
Cấu hình Draft: `dflash_3layer_17_19_25_33_34` (`middle_high`)
Tầng trích xuất từ Target: Layers [17, 19, 25, 33, 34] (trải rộng từ tầng giữa đến tầng ngọn)
Target Model: `Qwen2.5-VL-3B-Instruct` (36 decoder layers)
Tập dữ liệu: VideoDetailCaption (VDC50, N=50 video samples đã calibrate)
Ngân sách thị giác (Visual Budgets): 400, 3,000, 13,000, 25,000 visual tokens
Tổng số cases thực nghiệm: 1,200 cases (50 samples × 4 budgets × 6 conditions), hoàn tất 100%.

---

1. Tóm Tắt Tổng Quan

Cấu hình `middle_high` kết hợp cả tầng biểu diễn trung gian (layers 17, 19, 25) và các tầng quyết định ngôn ngữ cấp cao (layers 33, 34). - **Tốc độ sinh và Speculative Speedup:** Đạt đỉnh ở mức visual nhỏ (`400 tokens`) với **117.7 TPS** (Speedup **1.85x**) và giảm dần xuống **91.7 TPS** (Speedup **1.61x**) ở `3,000 tokens`, **30.2 TPS** ở `13,000 tokens`, và **10.2 TPS** ở `25,000 tokens`. - **Hành vi Visual Cut & Retention:** - Ở `400 tokens` và `3k tokens`, việc giữ đầy đủ visual (`full`) mang lại acceptance tốt hơn (`full` = 2.508 vs `cut` = 2.413 ở 400; `full` = 2.407 vs `cut` = 2.342 ở 3k). - Ở `13k tokens`, `full`, `cut` và các mức retention đạt acceptance gần như nhau ($\tau \approx 2.24$). - Ở `25k tokens`, **`retained_25` đạt acceptance cao nhất** (2.271 vs 2.209 ở `full`). - **Phân bổ Attention theo tầng:** Cấu hình này phân tán attention vào visual đều hơn giữa `layer 1` và `layer 2`: ở 25k tokens, `layer 1` có 66.2% visual mass và `layer 2` có 62.3% visual mass. - **Mật độ Attention (Density Ratio):** Token câu hỏi nhận mật độ attention cao gấp **11.1x** (ở 3k tokens), **31.7x** (ở 13k tokens) và lên tới **55.0x** (ở 25k tokens) so với mỗi token visual.

---

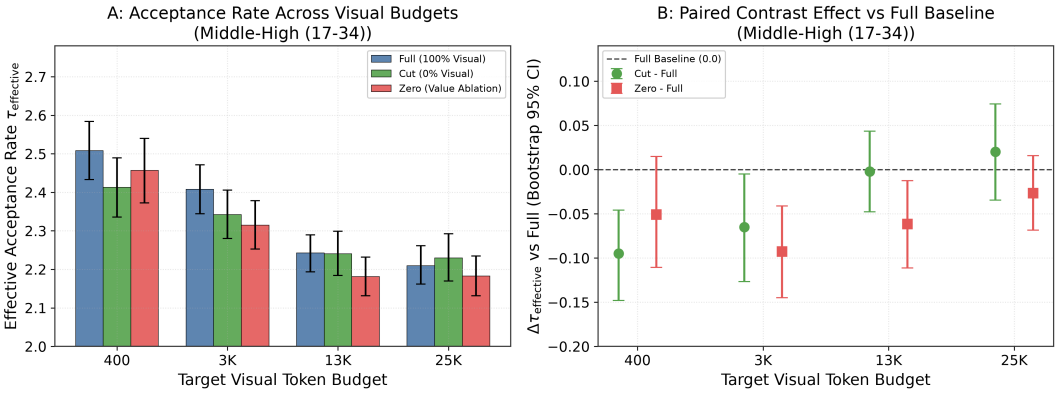
2. Thực Nghiệm 1: Visual Cut (`full` vs `zero` vs `cut`)

Bảng 1: Chỉ số Acceptance, Tốc độ và Tính Lossless theo Ngân Sách Visual

Budget (Tokens)	Điều kiện	$\tau_{effective}$ (Mean [95% CI])	$\tau_{proposal}$ (Mean)	TPS	Speedup	Lossless Rate
400	`full`	**2.508** [2.433, 2.584]	1.508	117.7	**1.85x**	10.0%
	`zero`	2.457 [2.372, 2.540]	1.457	112.1	1.77x	14.0%
	`cut`	2.413 [2.335, 2.490]	1.413	110.8	1.75x	16.0%
3,000	`full`	**2.407** [2.344, 2.471]	1.407	91.7	**1.61x**	0.0%
	`zero`	2.315 [2.253, 2.378]	1.315	87.1	1.53x	2.0%
	`cut`	2.342 [2.280, 2.406]	1.342	90.3	1.59x	0.0%
13,000	`full`	**2.242** [2.193, 2.290]	1.242	30.2	0.99x	6.0%
	`zero`	2.181 [2.132, 2.232]	1.181	29.7	0.97x	0.0%
	`cut`	2.240 [2.184, 2.299]	1.240	31.2	1.02x	0.0%
25,000	`full`	2.209 [2.162, 2.261]	1.209	10.2	1.26x	0.0%
	`zero`	2.183 [2.131, 2.235]	1.183	10.1	1.31x	4.0%
	`cut`	**2.229** [2.169, 2.293]	1.229	10.1	1.35x	0.0%

Bảng 2: Paired Contrasts (Hiệu số từng cặp so với `full` trên cùng video, Bootstrap 95% CI)

Budget	Contrast	Δ $\tau_{effective}$ [95% CI]	Δ TPS [95% CI]	Ý nghĩa Thống kê
400	cut - full	**-0.096** [-0.174, -0.016]	-6.9 [-11.8, -2.1]	**Giảm có ý nghĩa (Visual có ích)**
	zero - full	-0.051 [-0.141, +0.038]	-5.6 [-11.0, -0.5]	CI chứa 0
3,000	cut - full	**-0.065** [-0.126, -0.003]	-1.5 [-3.9, +1.0]	**Giảm nhẹ có ý nghĩa**
	zero - full	**-0.092** [-0.155, -0.029]	-4.6 [-7.3, -1.9]	**Zero tệ hơn Cut**
13,000	cut - full	-0.002 [-0.062, +0.057]	+1.0 [+0.2, +1.7]	CI chứa 0 (Bão hòa visual)
	zero - full	**-0.061** [-0.117, -0.006]	-0.5 [-1.2, +0.1]	**Zero làm giảm hiệu năng**
25,000	cut - full	+0.020 [-0.046, +0.088]	-0.1 [-0.6, +0.4]	CI chứa 0 (Cut ≥ Full)
	zero - full	-0.027 [-0.086, +0.032]	-0.1 [-0.6, +0.4]	CI chứa 0



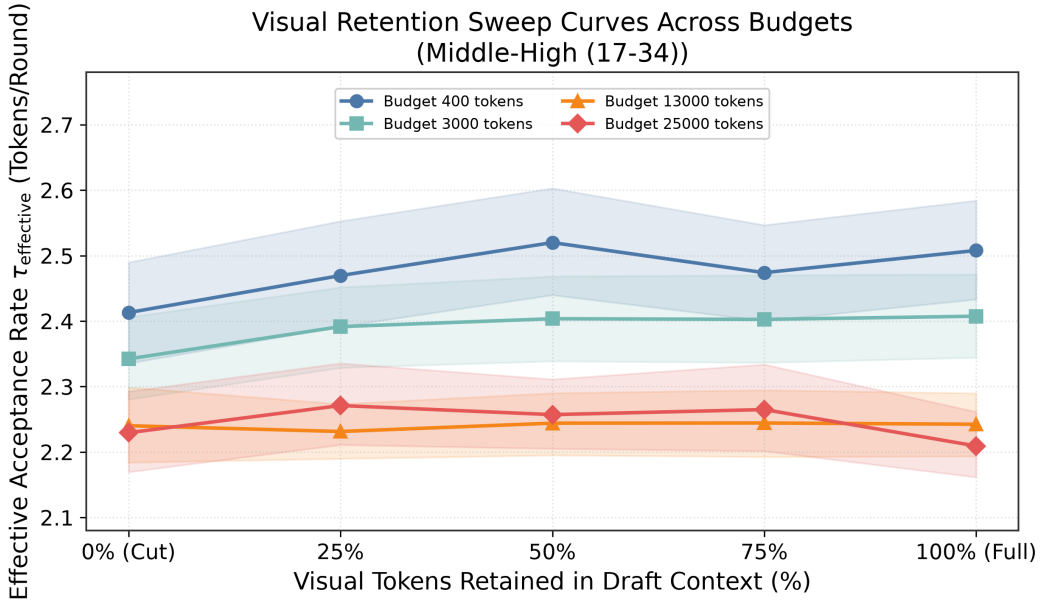
Hình 1: Đánh giá Visual Cut và Paired Contrasts so với Full (Middle-High)

---

3. Thực Nghiệm 2: Visual Retention (`100% → 75% → 50% → 25% → 0%`)

Bảng 3: Diễn tiến $\tau_{effective}$ qua các mức Retention

Budget	`full` (100%)	`retained_75` (75%)	`retained_50` (50%)	`retained_25` (25%)	`cut` (0%)
400 tokens	2.508 [2.433, 2.584]	2.474 [2.400, 2.547]	**2.520** [2.440, 2.603]	2.469 [2.392, 2.553]	2.413 [2.335, 2.490]
3,000 tokens	**2.407** [2.344, 2.471]	2.403 [2.337, 2.470]	2.404 [2.339, 2.468]	2.391 [2.329, 2.451]	2.342 [2.280, 2.406]
13,000 tokens	2.242 [2.193, 2.290]	2.244 [2.193, 2.295]	**2.244** [2.195, 2.290]	2.231 [2.190, 2.273]	2.240 [2.184, 2.299]
25,000 tokens	2.209 [2.162, 2.261]	2.265 [2.201, 2.334]	2.257 [2.205, 2.311]	**2.271** [2.211, 2.335]	2.229 [2.169, 2.293]



Hình 2: Đường cong Visual Retention Sweep qua các mức ngân sách (Middle-High)

MẸO & ĐIỂM TỐI ƯU

Tương tự như cấu hình `high_only`, ở mức 25,000 tokens, việc cắt giảm xuống `retained_25` giúp cải thiện $\tau_{effective}$ từ 2.209 lên **2.271**.

---

4. Thực Nghiệm 3: Phân Phối và Động Lực Học Attention

Bảng 4: Phân bổ Chi Tiết 100% Attention Mass và Mật Độ (Condition `full`)

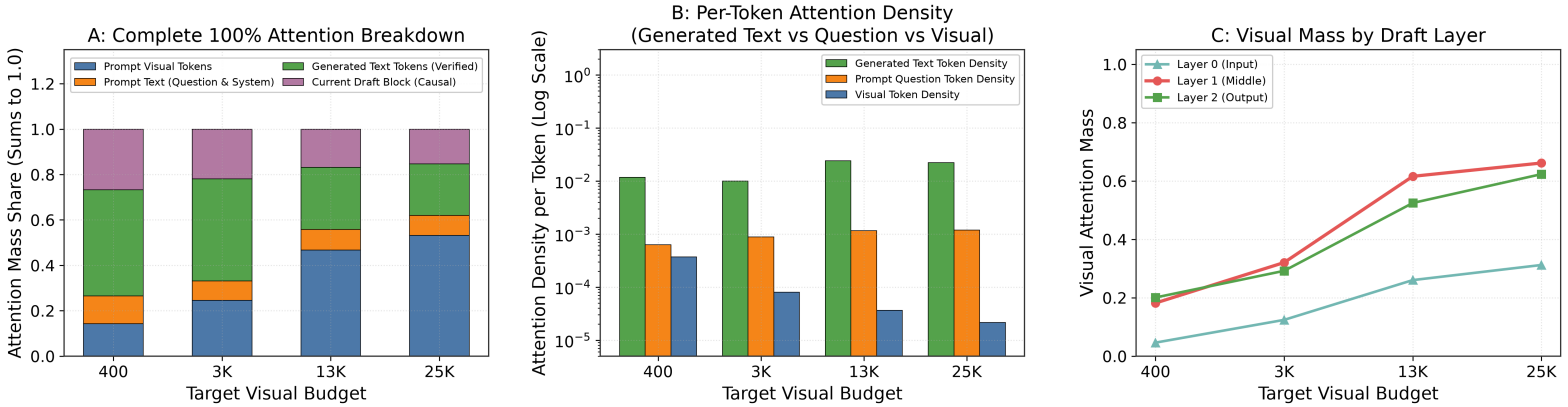
Budget (Tokens)	Prompt Visual Mass	Prompt Text Mass (Question)	Generated Text Mass (Đã Sinh)	Current Draft Block (Causal)	Tổng Mass	Mật Độ Generated Text / Visual	Mật Độ Question / Visual
400	0.143 (14.3%)	0.122 (12.2%)	**0.467 (46.7%)**	0.268 (26.8%)	**1.000**	**31.6x**	1.7x
3,000	0.246 (24.6%)	0.086 (8.6%)	**0.449 (44.9%)**	0.220 (22.0%)	**1.000**	**125.0x**	11.1x
13,000	**0.467 (46.7%)**	0.092 (9.2%)	0.273 (27.3%)	0.168 (16.8%)	**1.000**	**602.5x**	31.7x
25,000	**0.532 (53.2%)**	0.088 (8.8%)	0.227 (22.7%)	0.153 (15.3%)	**1.000**	**1,120.0x**	55.0x

LƯU Ý

Giải phẫu phân bổ 100% Attention Mass: 1. **Cân bằng giữa Video và Ngữ cảnh sinh:** Ở visual 400 và 3k tokens, Generated Text Tokens chiếm tới 45%–47% attention. Khi chuỗi video dài lên 13k–25k tokens, Visual Mass tăng lên ~53%, nhưng Generated Text vẫn duy trì ổn định 23%–27% để neo giữ mạch văn. 2. **Mật độ chú ý vượt bậc:** Mỗi token đã sinh ra nhận mật độ chú ý cao gấp **31x đến 1,120x** so với mỗi token video, chứng tỏ mô hình ưu tiên cực cao việc bám sát các từ vừa xuất hiện trong câu trả lời.

Bảng 5: Phân bổ Visual Attention Mass theo Tầng Draft (`layer 0`, `layer 1`, `layer 2`)

Budget	Layer 0 (Input projection)	Layer 1 (Middle processing)	Layer 2 (Output head)
400 tokens	0.046 (4.6%)	**0.182 (18.2%)**	**0.201 (20.1%)**
3,000 tokens	0.124 (12.4%)	**0.321 (32.1%)**	**0.292 (29.2%)**
13,000 tokens	0.260 (26.0%)	**0.616 (61.6%)**	**0.525 (52.5%)**
25,000 tokens	0.312 (31.2%)	**0.662 (66.2%)**	**0.623 (62.3%)**



Hình 3: Động lực học Attention: Phân bổ Mass, Density Ratio và Tầng Draft (Middle-High)

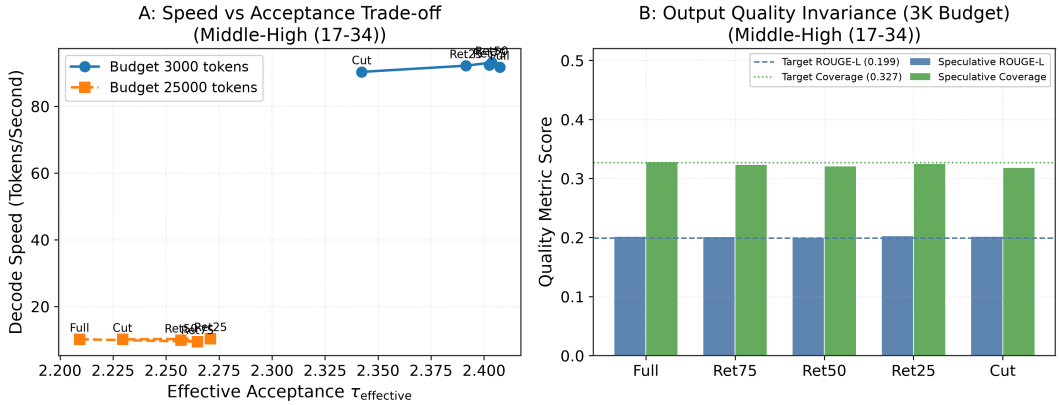
> **LƯU Ý**
> So với `high_only`, cấu hình `middle_high` có tầng cuối (`layer 2`) tham gia mạnh hơn vào visual context (62.3% visual mass ở 25k tokens), cho thấy các đặc trưng từ tầng 17-25 của Target được truyền sâu hơn tới đầu ra của Draft.

---

5. Chất Lượng Ngữ Nghĩa (Quality Metrics)

Bảng 6: Chỉ số Chất lượng Đầu ra (Speculative vs Target)

Budget	Điều kiện	Speculative BLEU	Target BLEU	Speculative ROUGE-L	Target ROUGE-L	Speculative Coverage	Target Coverage
400	full	0.044	0.046	0.181	0.184	0.212	0.213
	cut	0.044	0.046	0.184	0.184	0.221	0.213
3,000	full	0.045	0.043	0.201	0.198	0.328	0.317
	cut	0.046	0.043	0.201	0.198	0.318	0.317
13,000	full	0.040	0.042	0.196	0.199	0.338	0.353
	retained_25	0.043	0.042	0.201	0.199	0.355	0.353
25,000	full	0.040	0.042	0.200	0.200	0.338	0.342
	retained_25	0.042	0.042	0.196	0.200	0.343	0.342



Hình 4: Đánh giá Trade-off giữa Tốc độ và Acceptance cùng Tính Nhất Quán Chất Lượng (Middle-High)

---

6. Kết Luận Đánh Giá Cấu Hình `middle_high`

1. Tốc độ sinh ở visual 400 đạt **117.7 TPS** (nhanh nhất trong 4 cấu hình ở mức ngân sách này).
2. Sự kết hợp tầng giữa (17, 19, 25) giúp phân bổ biểu diễn thị giác đều qua các tầng draft, nhưng ở ngữ cảnh dài vẫn chịu hiện tượng dilution tương tự, với mật độ câu hỏi cao gấp **55x** so với visual tokens ở 25k.