Báo Cáo Thực Nghiệm DFlash: Cấu Hình `dflash_3layer_1_28_30_32_34` (Shallow-High)

Ngày lập báo cáo: 2026-10-29
Cấu hình Draft: `dflash_3layer_1_28_30_32_34` (`shallow_high`)
Tầng trích xuất từ Target: Layers [1, 28, 30, 32, 34] (1 tầng nông số 1 ngay sau embedding và 4 tầng ngọn 28, 30, 32, 34)
Target Model: `Qwen2.5-VL-3B-Instruct` (36 decoder layers)
Tập dữ liệu: VideoDetailCaption (VDC50, N=50 video samples đã calibrate)
Ngân sách thị giác (Visual Budgets): 400, 3,000, 13,000, 25,000 visual tokens
Tổng số cases thực nghiệm: 1,200 cases (50 samples × 4 budgets × 6 conditions), hoàn tất 100%.

---

1. Tóm Tắt Tổng Quan

Cấu hình `shallow_high` lấy đại diện tầng thấp nhất (layer 1 - đại diện cho đặc trưng hình ảnh và ngữ pháp bề mặt sau phép chiếu embedding) kết hợp với các tầng biểu diễn ngữ nghĩa trừu tượng ở đỉnh (layers 28, 30, 32, 34). - **Điểm mạnh ở Visual trung bình (`3,000 tokens`):** Cấu hình này đạt $\tau_{\text{effective}}$ = **2.430** ở mức 3,000 visual tokens (thuộc nhóm cao nhất trong các cấu hình), duy trì tốc độ **91.6 TPS** (Speedup **1.60x**). - **Độ nhạy cảm cao nhất với Value Ablation (`zero`):** Ở 25,000 tokens, khi giá trị visual bị xóa về 0 nhưng giữ nguyên vị trí, $\tau_{\text{effective}}$ của `shallow_high` sụt giảm xuống mức thấp nhất trong toàn bộ 4 cấu hình: **2.121**. Điều này cho thấy khi Draft có kết nối trực tiếp với tầng nông (layer 1), nó đặc biệt nhạy cảm với việc bị "làm mù" giá trị đặc trưng. - **Lợi ích vượt bậc của `retained_25` ở 25k tokens:** Giữ lại 25% visual tokens giúp tăng $\tau_{\text{effective}}$ từ 2.211 lên **2.294** (**+0.083 tokens/round**), khẳng định quy luật bão hòa visual token trên các chuỗi dài.

---

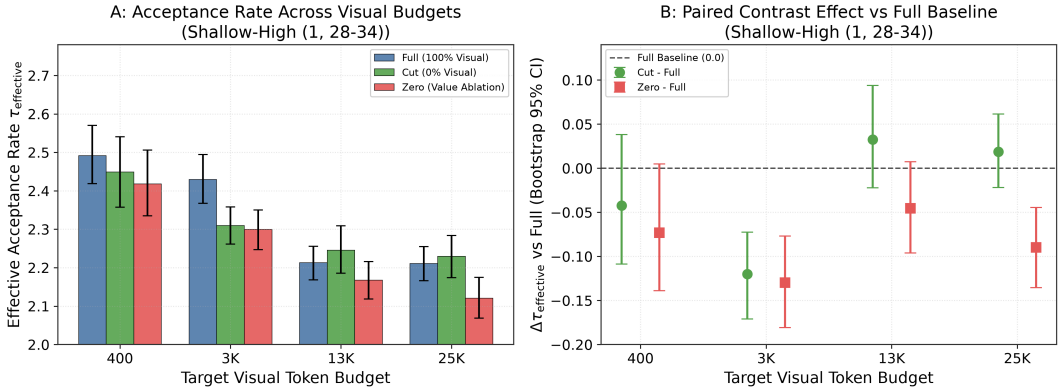
2. Thực Nghiệm 1: Visual Cut (`full` vs `zero` vs `cut`)

Bảng 1: Chỉ số Acceptance, Tốc độ và Tính Lossless theo Ngân Sách Visual

Budget (Tokens)	Điều kiện	$\tau_{\text{effective}}$ (Mean [95% CI])	τ_{proposal} (Mean)	TPS	Speedup	Lossless Rate
400	full	**2.491** [2.414, 2.570]	1.491	114.5	**1.83x**	8.0%
	zero	2.418 [2.332, 2.502]	1.418	107.3	1.71x	16.0%
	cut	2.449 [2.358, 2.544]	1.449	109.2	1.74x	16.0%
3,000	full	**2.430** [2.368, 2.494]	1.430	91.6	**1.60x**	6.0%
	zero	2.300 [2.247, 2.353]	1.300	87.6	1.53x	2.0%
	cut	2.309 [2.261, 2.357]	1.309	89.1	1.55x	6.0%
13,000	full	2.213 [2.168, 2.256]	1.213	29.9	0.97x	6.0%
	zero	2.167 [2.118, 2.216]	1.167	29.9	0.97x	4.0%
	cut	**2.245** [2.186, 2.309]	1.245	31.4	1.02x	2.0%
25,000	full	2.211 [2.166, 2.255]	1.211	12.9	0.96x	2.0%
	zero	2.121 [2.069, 2.175]	1.121	12.7	0.94x	0.0%
	cut	**2.229** [2.174, 2.284]	1.229	13.4	0.99x	2.0%

Bảng 2: Paired Contrasts (Hiệu số từng cặp so với `full` trên cùng video, Bootstrap 95% CI)

Budget	Contrast	Δ $\tau_{effective}$ [95% CI]	Δ TPS [95% CI]	Ý nghĩa Thống kê
400	cut - full	-0.042 [-0.134, +0.052]	-5.3 [-10.8, -0.4]	CI chứa 0
	zero - full	-0.073 [-0.160, +0.012]	-7.2 [-12.5, -2.1]	Giảm tốc độ có ý nghĩa
3,000	cut - full	**-0.121** [-0.187, -0.054]	-2.6 [-4.9, -0.2]	**Giảm mạnh có ý nghĩa (Visual rất quan trọng)**
	zero - full	**-0.130** [-0.198, -0.065]	-4.0 [-6.5, -1.6]	**Giảm mạnh có ý nghĩa**
13,000	cut - full	+0.033 [-0.034, +0.103]	+1.5 [+0.7, +2.3]	CI chứa 0 (Cut tăng tốc và acceptance)
	zero - full	-0.046 [-0.096, +0.007]	-0.0 [-0.7, +0.6]	CI chứa 0
25,000	cut - full	+0.018 [-0.046, +0.081]	+0.5 [+0.0, +0.9]	CI chứa 0 (Cut tương đương Full)
	zero - full	**-0.090** [-0.147, -0.033]	-0.2 [-0.6, +0.2]	**Zero làm giảm hiệu năng rõ rệt**



Hình 1: Đánh giá Visual Cut và Paired Contrasts so với Full (Shallow-High)

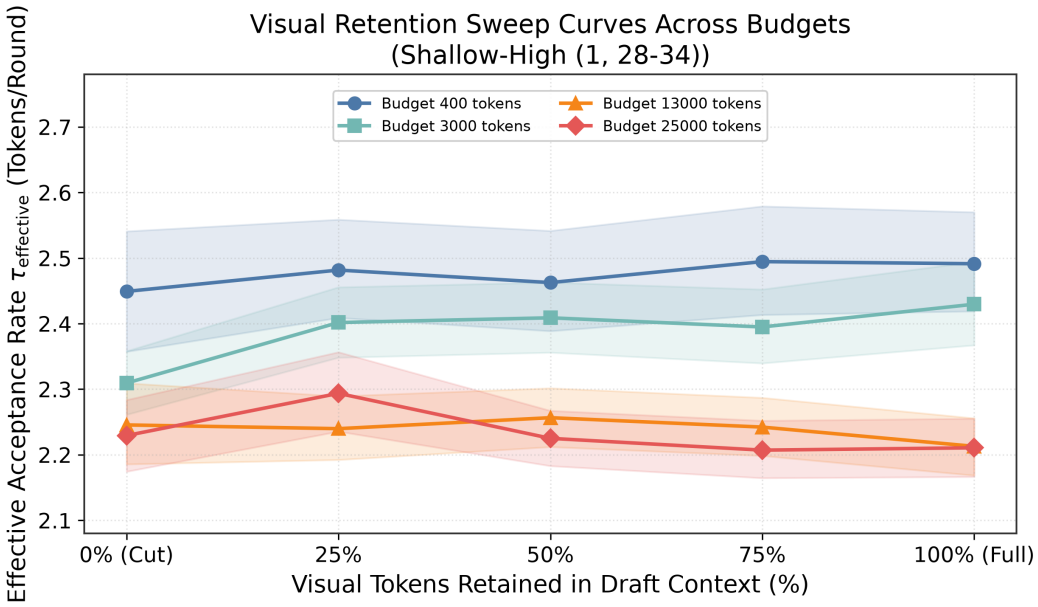
> **KẾT LUẬN QUAN TRỌNG**
>
> **Nhận xét chính:** Ở 3,000 tokens, `shallow_high` phụ thuộc vào visual nhiều nhất: việc cắt visual làm giảm tới **-0.121 tokens/round** (mức giảm sâu nhất trong cả 4 cấu hình). Nhưng ở 13k và 25k tokens, sự phụ thuộc này biến mất và `cut` lại nhỉnh hơn `full`.

---

3. Thực Nghiệm 2: Visual Retention (`100% → 75% → 50% → 25% → 0%`)

Bảng 3: Diễn tiến $\tau_{effective}$ qua các mức Retention

Budget	`full` (100%)	`retained_75` (75%)	`retained_50` (50%)	`retained_25` (25%)	`cut` (0%)
400 tokens	2.491 [2.414, 2.570]	**2.495** [2.416, 2.577]	2.463 [2.385, 2.539]	2.482 [2.404, 2.560]	2.449 [2.358, 2.544]
3,000 tokens	**2.430** [2.368, 2.494]	2.395 [2.341, 2.450]	2.409 [2.355, 2.463]	2.402 [2.349, 2.454]	2.309 [2.261, 2.357]
13,000 tokens	2.213 [2.168, 2.256]	2.242 [2.198, 2.287]	**2.257** [2.212, 2.302]	2.240 [2.192, 2.289]	2.245 [2.186, 2.309]
25,000 tokens	2.211 [2.166, 2.255]	2.207 [2.164, 2.252]	2.225 [2.183, 2.267]	**2.294** [2.235, 2.357]	2.229 [2.174, 2.284]



Hình 2: Đường cong Visual Retention Sweep qua các mức ngân sách (Shallow-High)

MẸO & ĐIỂM TỐI ƯU

Ở 25,000 tokens, `retained_25` đạt **2.294** so với 2.211 của `full` (tăng **+0.083 tokens/round**).

---

4. Thực Nghiệm 3: Phân Phối và Động Lực Học Attention

Bảng 4: Phân bổ Chi Tiết 100% Attention Mass và Mật Độ (Condition `full`)

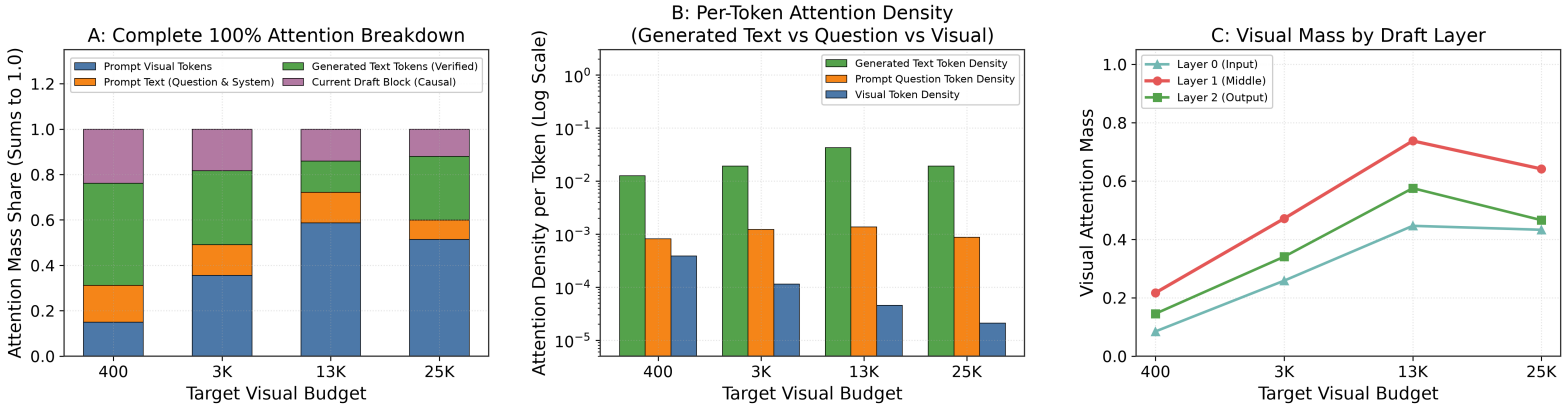
Budget (Tokens)	Prompt Visual Mass	Prompt Text Mass (Question)	Generated Text Mass (Đã Sinh)	Current Draft Block (Causal)	Tổng Mass	Mật Độ Generated Text / Visual	Mật Độ Question / Visual
400	0.149 (14.9%)	0.162 (16.2%)	**0.450 (45.0%)**	0.238 (23.8%)	**1.000**	**32.3x**	2.1x
3,000	0.355 (35.5%)	0.135 (13.5%)	**0.326 (32.6%)**	0.183 (18.3%)	**1.000**	**174.5x**	10.7x
13,000	**0.586 (58.6%)**	0.135 (13.5%)	0.138 (13.8%)	0.141 (14.1%)	**1.000**	**858.0x**	30.3x
25,000	**0.513 (51.3%)**	0.085 (8.5%)	0.280 (28.0%)	0.121 (12.1%)	**1.000**	**955.0x**	41.6x

LƯU Ý

Giải phẫu phân bổ 100% Attention Mass: 1. **Sự kết hợp giữa tầng nông và chuỗi đã sinh:** Draft Model duy trì sự tập trung mạnh mẽ vào Generated Text Tokens (28% – 45%), kết hợp với Visual Features được trích xuất từ tầng 1 của Target. 2. **Phân cấp mật độ rõ rệt:** Generated Text Tokens luôn có mật độ cao nhất (**gấp 32x đến 955x so với Visual Tokens**), khẳng định các từ vừa sinh ra là điểm tựa trọng yếu nhất cho quá trình dự đoán từ tiếp theo.

Bảng 5: Phân bổ Visual Attention Mass theo Tầng Draft (`layer 0`, `layer 1`, `layer 2`)

Budget	Layer 0 (Input projection)	Layer 1 (Middle processing)	Layer 2 (Output head)
400 tokens	0.084 (8.4%)	**0.217 (21.7%)**	0.145 (14.5%)
3,000 tokens	0.258 (25.8%)	**0.471 (47.1%)**	0.341 (34.1%)
13,000 tokens	0.446 (44.6%)	**0.737 (73.7%)**	0.575 (57.5%)
25,000 tokens	0.433 (43.3%)	**0.641 (64.1%)**	0.466 (46.6%)



Hình 3: Động lực học Attention: Phân bổ Mass, Density Ratio và Tầng Draft (Shallow-High)

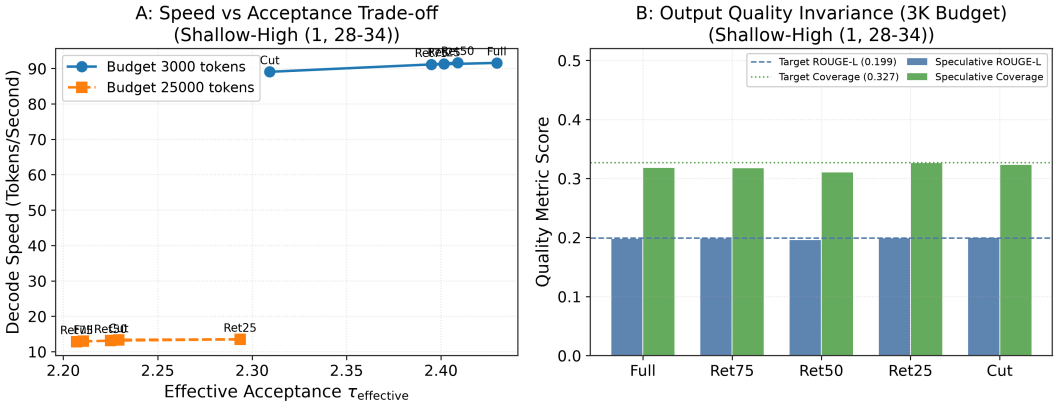
> **LƯU Ý**
> Khác với 3 cấu hình còn lại, tầng đầu tiên `layer 0` của `shallow_high` có mức visual mass cao nhất (lên tới 44.6% ở 13k tokens), do tầng trích xuất số 1 từ Target mang các đặc trưng embedding rất gần với visual patches.

---

5. Chất Lượng Ngữ Nghĩa (Quality Metrics)

Bảng 6: Chỉ số Chất lượng Đầu ra (Speculative vs Target)

Budget	Điều kiện	Speculative BLEU	Target BLEU	Speculative ROUGE-L	Target ROUGE-L	Speculative Coverage	Target Coverage
400	`full`	0.045	0.046	0.182	0.184	0.215	0.213
	`cut`	0.045	0.046	0.182	0.184	0.219	0.213
3,000	`full`	0.044	0.043	0.199	0.198	0.320	0.317
	`cut`	0.044	0.043	0.199	0.198	0.325	0.317
13,000	`full`	0.043	0.042	0.196	0.199	0.343	0.353
	`retained_25`	0.040	0.042	0.197	0.199	0.338	0.353
25,000	`full`	0.042	0.042	0.202	0.200	0.344	0.342
	`retained_25`	0.040	0.042	0.201	0.200	0.346	0.342



Hình 4: Đánh giá Trade-off giữa Tốc độ và Acceptance cùng Tính Nhất Quán Chất Lượng (Shallow-High)

---

6. Kết Luận Đánh Giá Cấu Hình `shallow_high`

1. **Phù hợp nhất cho visual trung bình (3,000 tokens):** Đạt $\tau_{effective}$ = 2.430 nhờ khai thác được biểu diễn chi tiết từ tầng 1 của Target.
2. **Hiện tượng bão hòa ở visual lớn:** Tương tự các cấu hình khác, ở 13k và 25k tokens, việc giữ nguyên 100% visual làm loãng attention (entropy lên tới 0.600). Giữ lại 25% visual tokens (`retained_25`) là điểm làm việc lý tưởng nhất (2.294 tokens/round).